朴素贝叶斯算法 & 应用实例

引

和师弟师妹聊天时经常提及，若有志于从事数据挖掘、机器学习方面的工作，在大学阶段就要把基础知识都带上。 机器学习在大数据浪潮中逐渐展示她的魅力，其实《概率论》、《微积分》、《线性代数》、《运筹学》、《信息论》等几门课程算是前置课程，当然要转化为工程应用的话，编程技能也是需要的，而作为信息管理专业的同学，对于信息的理解、数据的敏感都是很好的加分项。

不过光说不练，给人的留下的印象是极为浅薄的，从一些大家都熟悉的角度切入，或许更容易能让人有所体会。

下面进入正题。

BTW, 如果观点错误或者引用侵权的欢迎指正交流。

一、朴素贝叶斯算法介绍

朴素贝叶斯，之所以称为朴素，是因为其中引入了几个假设（不用担心，下文会提及）。而正因为这几个假设的引入，使得模型简单易理解，同时如果训练得当，往往能收获不错的分类效果，因此这个系列以 naive bayes 开头和大家见面。

因为朴素贝叶斯是贝叶斯决策理论的一部分，所以我们先快速了解一下贝叶斯决策理论。

假设有一个数据集，由两类组成（简化问题），对于每个样本的分类，我们都已经知晓。数据分布如下图（图取自 MLiA）：

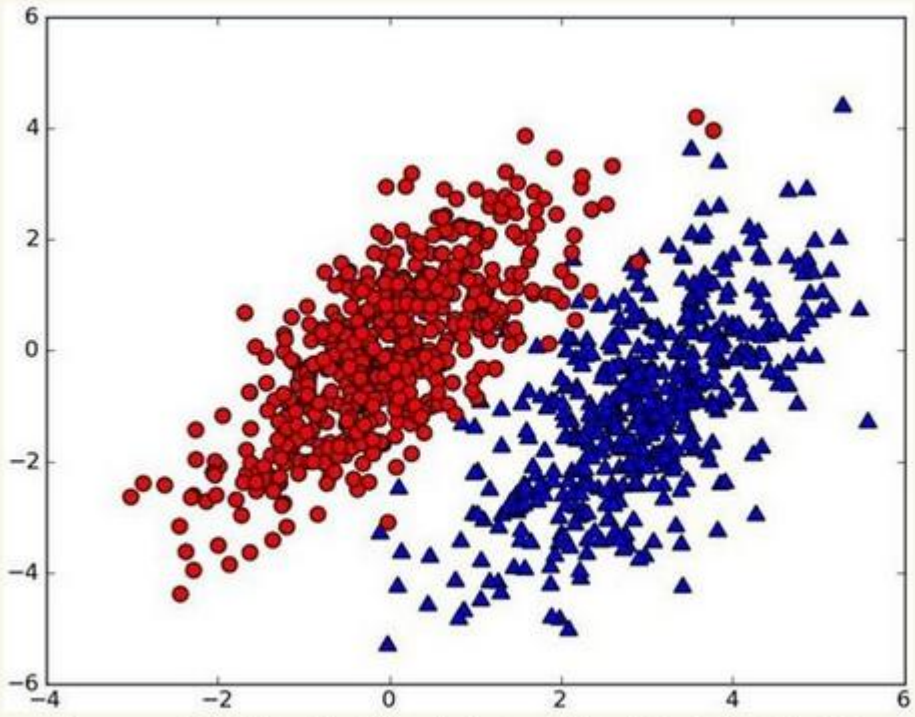

图4-1　两个参数已知的概率分布，参数决定了分布的形状

现在出现一个新的点 new_point (x,y)，其分类未知。我们可以用 p1(x,y) 表示数据点 (x,y) 属于红色一类的概率，同时也可以用 p2(x,y) 表示数据点 (x,y) 属于蓝色一类的概率。那要把 new_point 归在红、蓝哪一类呢？

我们提出这样的规则：

如果 p1(x,y) > p2(x,y)，则 (x,y) 为红色一类。

如果 p1(x,y) <p2(x,y)，则 (x,y) 为蓝色一类。

换人类的语言来描述这一规则：选择概率高的一类作为新点的分类。这就是贝叶斯决策理论的核心思想，即选择具有最高概率的决策。

用条件概率的方式定义这一贝叶斯分类准则：

如果 p(red|x,y) > p(blue|x,y), 则 (x,y) 属于红色一类。

如果 p(red|x,y) < p(blue|x,y), 则 (x,y) 属于蓝色一类。

也就是说，在出现一个需要分类的新点时，我们只需要计算这个点的

max(p(c1 | x,y),p(c2 | x,y),p(c3 | x,y)...p(cn| x,y))。其对于的最大概

率标签，就是这个新点的分类啦。

那么问题来了，对于分类 i 如何求解 p(ci| x,y)？

没错，就是贝叶斯公式：

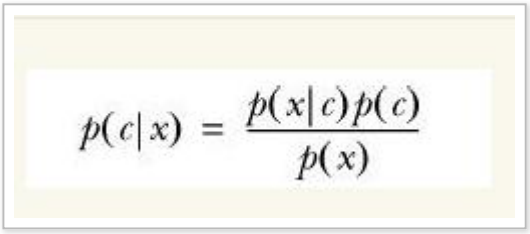

公式暂不推导，先描述这个转换的重要性。红色、蓝色分类是为了帮助理解，这里要换成多维度说法了，也就是第二部分的实例：判断一条微信朋友圈是不是广告。

前置条件是：我们已经拥有了一个平日广大用户的朋友圈内容库，这些朋友圈当中，如果真的是在做广告的，会被 “热心网友” 打上 “广告” 的标签，我们要做的是把所有内容分成一个一个词，每个词对应一个维度，构建一个高维度空间 (别担心，这里未出现向量计算)。

当出现一条新的朋友圈 new_post，我们也将其分词，然后投放到朋友圈词库空间里。

这里的 X 表示多个特征（词）x1,x2,x3... 组成的特征向量。

P(ad|x) 表示：已知朋友圈内容而这条朋友圈是广告的概率。

利用贝叶斯公式，进行转换：

P(ad|X) = p(X|ad) p(ad) / p(X)

P(not-ad | X) = p(X|not-ad)p(not-ad) / p(X)

比较上面两个概率的大小，如果 p(ad|X) > p(not-ad|X)，则这条朋友圈被划分为广告，反之则不是广告。

看到这儿，实际问题已经转为数学公式了。

看公式推导 (公式图片 引用)：

朴素贝叶斯分类的正式定义如下：

1、设

$$x = \{a_1, a_2, ..., a_m\}$$

为一个待分类项，而每个 a 为 x 的一个特征属性。

2、有类别集合

$$C = \{y_1, y_2, ..., y_n\}$$

。

3、计算

$$P(y_1|x), P(y_2|x), ..., P(y_n|x)$$

。

4、如果

$$P(y_k|x) = max\{P(y_1|x), P(y_2|x), ..., P(y_n|x)\}$$

，则

$$x \in y_k$$

。

那么现在的关键就是如何计算第 3 步中的各个条件概率。我们可以这么做：

1、找到一个已知分类的待分类项集合，这个集合叫做训练样本集。

2、统计得到在各类别下各个特征属性的条件概率估计。即。

3、如果各个特征属性是条件独立的，则根据贝叶斯定理有如下推导：

$$P(y_i|x) = \frac{P(x|y_i)P(y_i)}{P(x)}$$

因为分母对于所有类别为常数，因为我们只要将分子最大化皆可。又因为各特征属性是条件独立的，所以有：

$$P(x|y_i)P(y_i) = P(a_1|y_i)P(a_2|y_i)...P(a_m|y_i)P(y_i) = P(y_i)\prod_{j=1}^{m} P(a_j|y_i)$$

这里要引入朴素贝叶斯假设了。如果认为每个词都是独立的特征，那么朋友圈内容向量可以展开为分词 (x1,x2,x3...xn)，因此有了下面的公式推导：

P(ad|X) = p(X|ad)p(ad) = p(x1, x2, x3, x4...xn | ad) p(ad)

假设所有词相互条件独立，则进一步拆分：

P(ad|X) = p(x1|ad)p(x2|ad)p(x3|ad)...p(xn|ad) p(ad)

虽然现实中，一条朋友圈内容中，相互之间的词不会是相对独立的，因为我们的自然语言是讲究上下文的ヽ(ゝ▽〈)ノ，不过这也是朴素贝叶斯的朴素所在，简单的看待问题。

看公式 p(ad|X)=p(x1|ad)p(x2|ad)p(x3|ad)...p(xn|ad) p(ad)

至此，P(xi|ad) 很容易求解，P(ad) 为词库中广告朋友圈占所有朋友圈（训练集）的概率。我们的问题也就迎刃而解了。

二、构造一个文字广告过滤器。

到这里，应该已经有心急的读者掀桌而起了，捣鼓半天，没有应用。(ﾉ'□')ﾉ ┻┻

"Talk is cheap, show me the code."

逻辑均在代码注释中，因为用 python 编写，和伪代码没啥两样，而且我也懒得画图……

```python
#encoding:UTF-8
'''
Author: marco lin
Date: 2015-08-28
'''

from numpy import *
import pickle
import jieba
import time

stop_word = []
'''
    停用词集，包含“啊，吗，嗯”一类的无实意词汇以及标点符号
'''
def loadStopword():
    fr = open('stopword.txt', 'r')
    lines = fr.readlines()
    for line in lines:
        stop_word.append(line.strip().decode('utf-8'))
    fr.close()

'''
    创建词集
    params:
        documentSet 为训练文档集
    return:词集，作为词袋空间
'''
def createVocabList(documentSet):
    vocabSet = set([])
    for document in documentSet:
        vocabSet = vocabSet | set(document) #union of the two sets
    return list(vocabSet)

'''
    载入数据
'''
def loadData():
    return None

'''
   文本处理，如果是未处理文本，则先分词（jieba分词）,再去除停用词
'''
def textParse(bigString, load_from_file=True):    #input is big st
    if load_from_file:
        listOfWord = bigString.split('/ ')

        listOfWord = [x for x in listOfWord if x != ' ']
        return listOfWord
    else:
        cutted = jieba.cut(bigString, cut_all=False)
        listOfWord  = []
```

```
        for word in cutted:
            if word not in stop_word:
                listOfWord.append(word)
        return [word.encode('utf-8') for word in listOfWord]

'''
    交叉训练
'''
CLASS_AD        = 1
CLASS_NOT_AD    = 0

def testClassify():
    listADDoc = []
    listNotADDoc = []
    listAllDoc = []
    listClasses = []

    print "----loading document list----"

    #两千个标注为广告的文档
    for i in range(1, 1001):
        wordList = textParse(open('subject/subject_ad/%d.txt' % i)
        listAllDoc.append(wordList)
        listClasses.append(CLASS_AD)
    #两千个标注为非广告的文档
    for i in range(1, 1001):
        wordList = textParse(open('subject/subject_notad/%d.txt' %
        listAllDoc.append(wordList)
        listClasses.append(CLASS_NOT_AD)

    print "----creating vocab list----"
    #构建词袋模型
    listVocab = createVocabList(listAllDoc)

    docNum = len(listAllDoc)
    testSetNum  = int(docNum * 0.1);

    trainingIndexSet = range(docNum)    # 建立与所有文档等长的空数据集
    testSet = []                        # 空测试集

    # 随机索引，用作测试集，同时将随机的索引从训练集中剔除
    for i in range(testSetNum):
        randIndex = int(random.uniform(0, len(trainingIndexSet)))
        testSet.append(trainingIndexSet[randIndex])
        del(trainingIndexSet[randIndex])

    trainMatrix = []
    trainClasses = []

    for docIndex in trainingIndexSet:
        trainMatrix.append(bagOfWords2VecMN(listVocab, listAllDoc[
        trainClasses.append(listClasses[docIndex])

```

```
105     print "----traning begin----"
106     pADV, pNotADV, pClassAD = trainNaiveBayes(array(trainMatrix),
107
108     print "----traning complete----"
109     print "pADV:", pADV
110     print "pNotADV:", pNotADV
111     print "pClassAD:", pClassAD
112     print "ad: %d, not ad:%d" % (CLASS_AD, CLASS_NOT_AD)
113
114     args = dict()
115     args['pADV'] = pADV
116     args['pNotADV'] = pNotADV
117     args['pClassAD'] = pClassAD
118
119     fw = open("args.pkl", "wb")
120     pickle.dump(args, fw, 2)
121     fw.close()
122
123     fw = open("vocab.pkl", "wb")
124     pickle.dump(listVocab, fw, 2)
125     fw.close()
126
127     errorCount = 0
128     for docIndex in testSet:
129         vecWord = bagOfWords2VecMN(listVocab, listAllDoc[docIndex]
130         if classifyNaiveBayes(array(vecWord), pADV, pNotADV, pClas
131             errorCount += 1
132             doc = ' '.join(listAllDoc[docIndex])
133             print "classfication error", doc.decode('utf-8', "igno
134     print 'the error rate is: ', float(errorCount) / len(testSet)
135
136 # 分类方法(这边只做二类处理)
137 def classifyNaiveBayes(vec2Classify, pADVec, pNotADVec, pClass1):
138     pIsAD = sum(vec2Classify * pADVec) + log(pClass1)    #element-
139     pIsNotAD = sum(vec2Classify * pNotADVec) + log(1.0 - pClass1)
140
141     if pIsAD > pIsNotAD:
142         return CLASS_AD
143     else:
144         return CLASS_NOT_AD
145
146 '''
147     训练
148     params:
149         tranMatrix 由测试文档转化成的词空间向量 所组成的 测试矩阵
150         tranClasses 上述测试文档对应的分类标签
151 '''
152 def trainNaiveBayes(trainMatrix, trainClasses):
153     numTrainDocs = len(trainMatrix)
154     numWords = len(trainMatrix[0]) #计算矩阵列数, 等于每个向量的维数
155     numIsAD  = len(filter(lambda x: x == CLASS_AD, trainClasses))
156     pClassAD = numIsAD / float(numTrainDocs)
157     pADNum = ones(numWords); pNotADNum = ones(numWords)
```

```
158     pADDenom = 2.0; pNotADDenom = 2.0
159
160     for i in range(numTrainDocs):
161         if trainClasses[i] == CLASS_AD:
162             pADNum += trainMatrix[i]
163             pADDenom += sum(trainMatrix[i])
164         else:
165             pNotADNum += trainMatrix[i]
166             pNotADDenom += sum(trainMatrix[i])
167
168     pADVect = log(pADNum / pADDenom)
169     pNotADVect = log(pNotADNum / pNotADDenom)
170
171     return pADVect, pNotADVect, pClassAD
172
173 '''
174     将输入转化为向量，其所在空间维度为 len(listVocab)
175     params:
176         listVocab-词集
177         inputSet-分词后的文本，存储于set
178 '''
179 def bagOfWords2VecMN(listVocab, inputSet):
180     returnVec = [0]*len(listVocab)
181     for word in inputSet:
182         if word in listVocab:
183             returnVec[listVocab.index(word)] += 1
184     return returnVec
185
186 '''
187     读取保存的模型，做分类操作
188 '''
189 def adClassify(text):
190     fr = open("args.pkl", "rb")
191     args = pickle.load(fr)
192     pADV        = args['pADV']
193     pNotADV     = args['pNotADV']
194     pClassAD    = args['pClassAD']
195     fr.close()
196
197     fr = open("vocab.pkl", "rb")
198     listVocab = pickle.load(fr)
199     fr.close()
200
201     if len(listVocab) == 0:
202         print "got no args"
203         return
204
205     text = textParse(text, False)
206     vecWord = bagOfWords2VecMN(listVocab, text)
207     class_type = classifyNaiveBayes(array(vecWord), pADV, pNotADV,
208
209     print "classfication type:%d" % class_type
210
```

```
211
212 if __name__ == "__main__":
213     loadStopword()
214     while True:
215         opcode = raw_input("input 1 for training, 2 for ad classif
216         if opcode.strip() == "1":
217             begtime = time.time()
218             testClassify()
219             print "cost time total:", time.time() - begtime
220         else:
221             text = raw_input("input the text:")
222             adClassify(text)
223
```

View Code

代码测试效果：

1、训练。

```
input 1 for training, 2 for ad classify: 1
----loading document list----
----creating vocab list----
----traning begin----
----traning complete----
pADV: [-10.9715719  -10.9715719  -10.27842472 ...,  -9.36213399 -10.27842472
  -9.58527754]
pNotADV: [-10.63230347 -10.63230347 -11.32545065 ..., -11.32545065 -11.325450
 -10.22683836]
pClassAD: 0.496666666667
ad: 1, not ad:0
```

```
the error rate is:  0.125
cost time total: 93.8680000305
input 1 for training, 2 for ad classify: 2
```

2、实例测试。

分类为 1 则归为广告，0 为普通文本。

```
input 1 for training, 2 for ad classify: 2
input the text:新人发帖  吧中大神速来围观~~~
classfication type:0
input 1 for training, 2 for ad classify: 2
input the text:「多图」震惊的社会百态！你能坚持看到第几张？
```

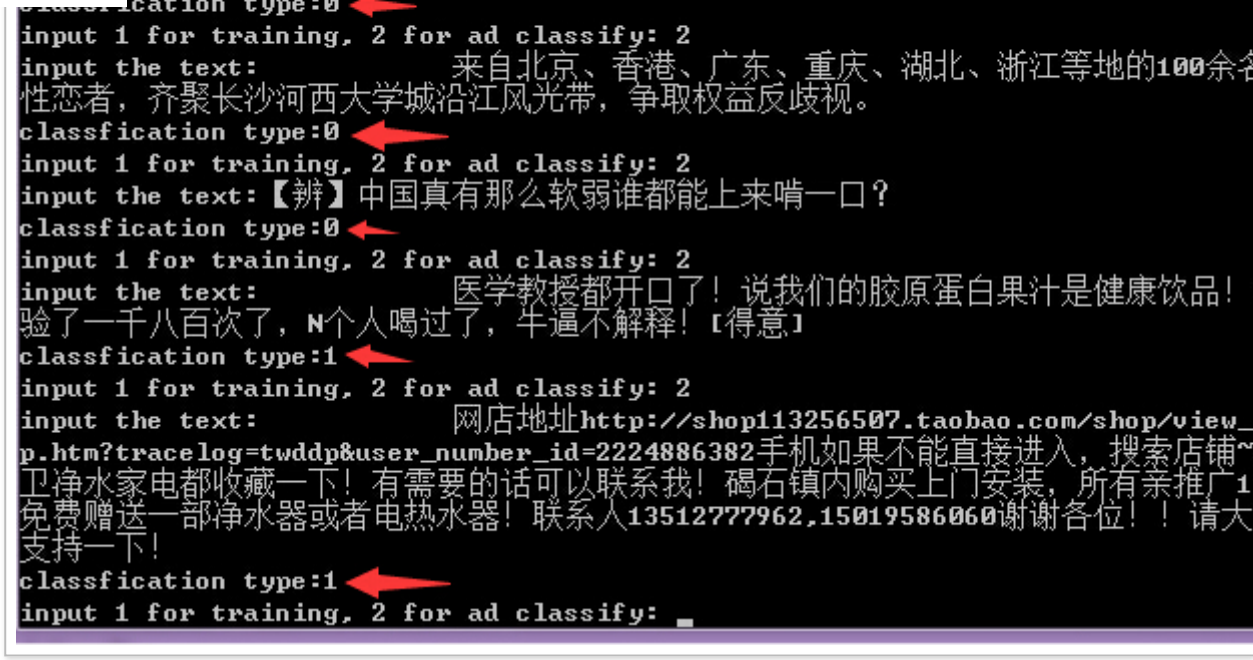

p.s.

此分类器的准确率，其实是比较依赖于训练语料的，机器学习算法就和纯洁的小孩一样，取决于其成长（训练）条件，“吃的是草挤的是奶”，但，“不是所有的牛奶，都叫特仑苏”。

全文完